EMR
Elastic MapReduce

Eduardo Viera

Javier Rico

Introducción

El nombre EMR viene de Amazon Elastic MapReduce, aunque hoy AWS lo presenta como una plataforma más amplia para ejecutar frameworks de big data, no solo MapReduce.

¿Qué es EMR?

Amazon EMR es una plataforma administrada de clústeres que simplifica la ejecución de herramientas como Apache Hadoop y Apache Spark sobre AWS.
Su objetivo es evitar montar toda la infraestructura manualmente.

01

Servicio de AWS
para procesamiento de datos a gran escala.

02

Plataforma administrada
para ejecutar frameworks de big data.

03

Análisis y Transformación
Permite analizar, transformar y mover grandes volúmenes de datos.

¿Para qué se utiliza?

01

Análisis de Big Data:
Procesa datos a gran escala para descubrir patrones ocultos.

02

ETL y pipelines de datos:
Extrae, transforma y prepara datos desde múltiples fuentes a escala.

03

Procesamiento en tiempo real:
Analiza flujos de datos en streaming para casos de monitoreo y respuesta inmediata.

04

Preparación de datos para Machine Learning:
Ejecuta procesamiento distribuido para entrenar y alimentar modelos con frameworks como Apache Spark.

Arquitectura de EMR

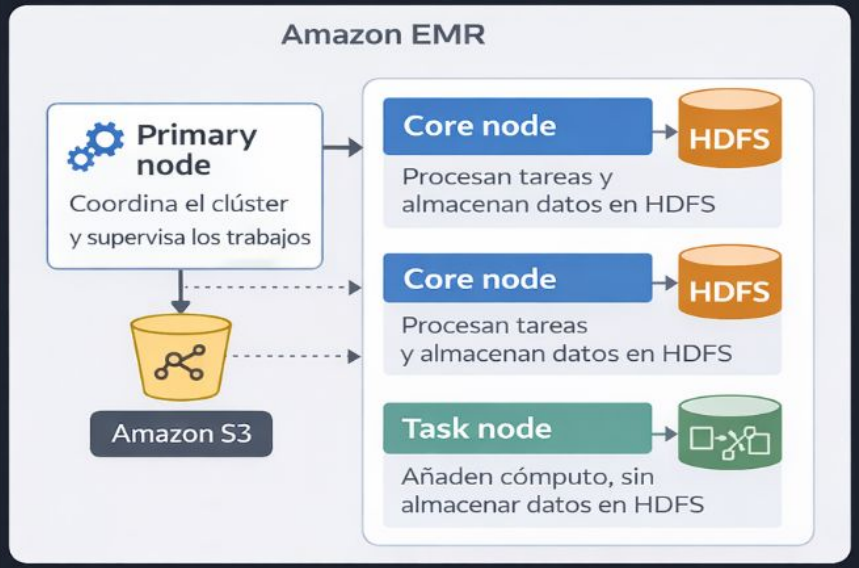

Primary node: Coordina el clúster, administra recursos y supervisa la ejecución de los trabajos.

Core nodes: Ejecutan tareas de procesamiento y almacenan datos en HDFS del clúster..

Task nodes: Añaden capacidad de cómputo para procesamiento paralelo, sin almacenar datos en HDFS.

Nota: En muchos entornos, Amazon S3 se usa como almacenamiento persistente y HDFS para datos temporales.

Funcionamiento de EMR

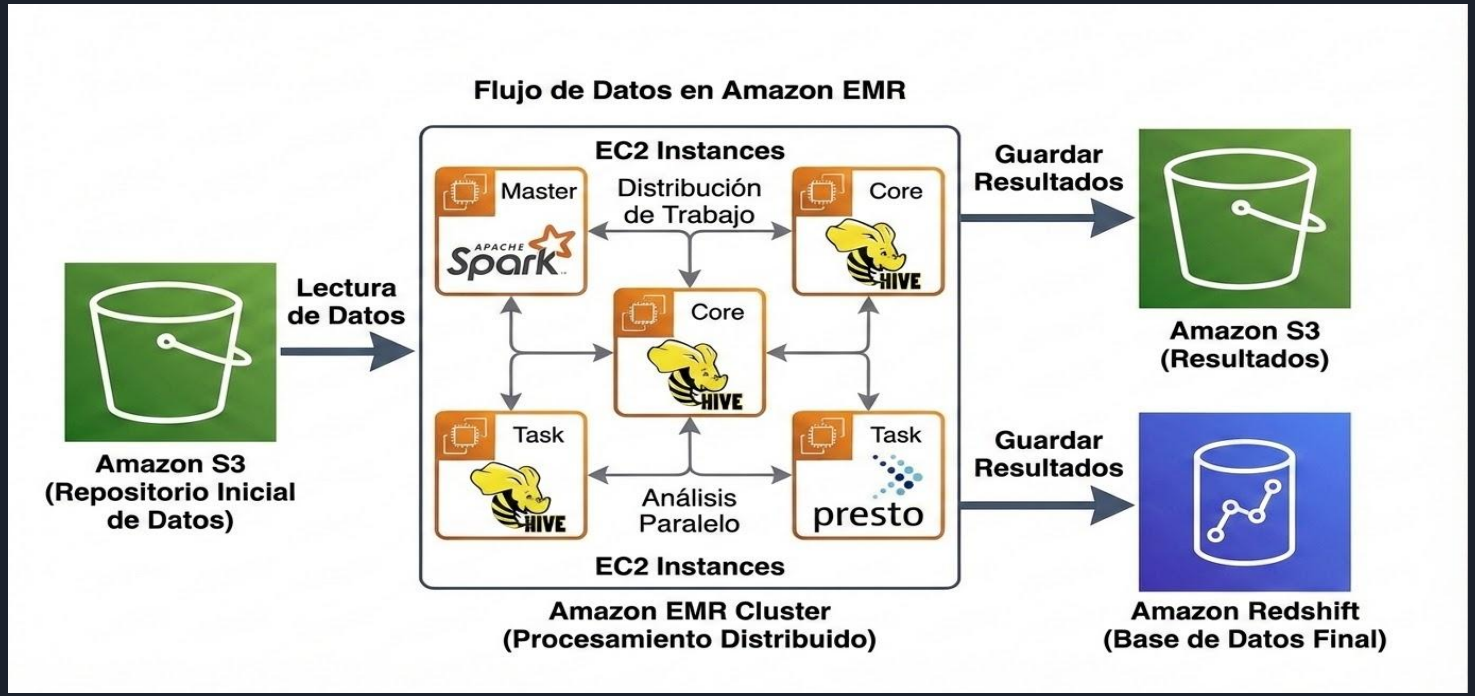

Características principales

Servicio Gestionado

AWS hace el trabajo pesado se encarga de aprovisionar, configurar y ajustar los servidores por ti.

Escalabilidad Elástica

El clúster puede crecer o encogerse automáticamente sobre la marcha dependiendo de la cantidad de datos que necesites procesar.

Rentabilidad

Pagas por segundo de uso y permite utilizar Instancias Spot para reducir costes drásticamente.

Almacenamiento Flexible

Se integra de forma nativa y directa con Amazon S3.

Ecosistema Open Source

Es compatible con las herramientas líderes de Big Data de la industria, como Apache Spark, Hadoop, Hive o Presto.

¿Qué problemas resuelve?

Procesar datasets demasiado grandes para un solo equipo.

Escalar recursos según la carga.

Reducir la complejidad de instalar y mantener Hadoop/Spark.

Mejorar tiempos de procesamiento.

Casos de Usos

Procesamiento masivo de logs

Análisis de grandes volúmenes de datos

ETL de datos

Transformación de archivos CSV/JSON/Parquet

Análisis de datos para business intelligence

Preparación de datos para machine learning

Ejemplo Real:

Una empresa guarda millones de registros en S3 y usa EMR con Spark para limpiarlos, agruparlos y generar resultados para analizarlos después

Objetivo de la Práctica

Fuente de Datos

Conjunto de datos real de egresados de FP.

Almacenamiento

Ingesta y guardado en Amazon S3.

Procesamiento

Análisis y transformación con EMR.

Variables más importantes del dataset

Identificación y Temporalidad

TIME_PERIOD: Periodo o año de referencia.

TIEMPO_EGRESO: Tiempo transcurrido desde el egreso.

Perfil del Egresado

SEXO: Categoría de sexo.

TITULACION: Titulación o familia profesional.

MODALIDAD_FORMACION: Modalidad de formación.

LUGAR_RESIDENCIA: Ámbito territorial considerado.

Situación Laboral

RELACION_ACTIVIDAD: Situación del egresado respecto a la actividad.

Métricas y Datos

MEDIDAS: Tipo de medida (número o porcentaje).

OBS_VALUE: # Valor numérico asociado a la observación.

Subida dataset al S3

1. Acceder

Acceder al servicio Amazon S3 desde la consola de AWS.

2. Crear Bucket

Crear un bucket para almacenar los archivos de la práctica.

3. Subir Archivo

Subir al bucket el archivo observations.tsv.

4. Organizar

Organizar el archivo dentro de una ruta o carpeta para mantener una mejor estructura del proyecto.

Ejemplo de organización dentro del bucket:

`s3://edu-javi-bucket/dataset/observations.tsv`

Subida dataset al S3

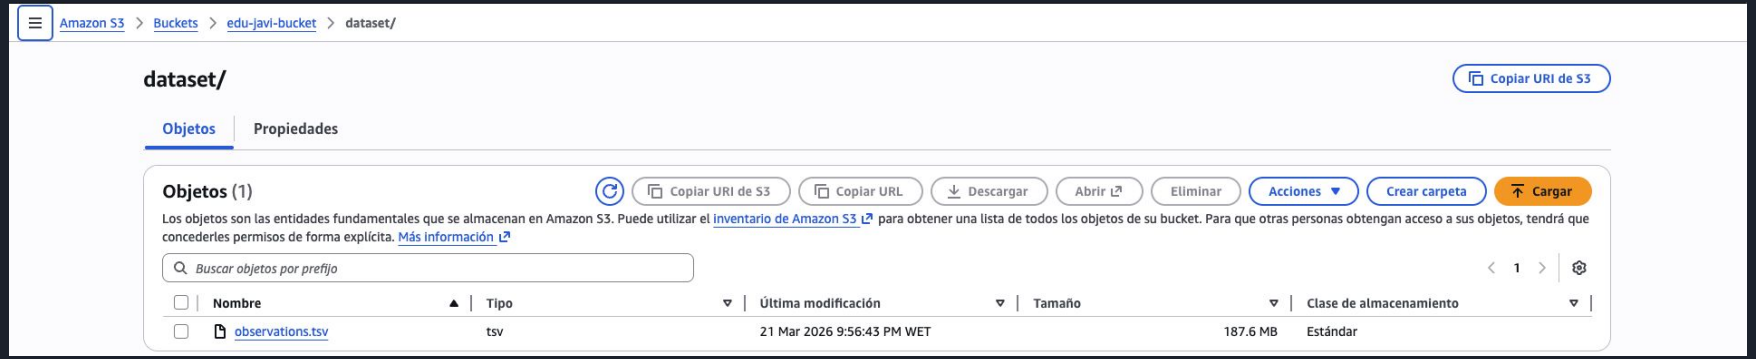

Preparación del entorno en Amazon EMR

Después de almacenar el dataset en Amazon S3, se procedió a preparar el entorno de trabajo en Amazon EMR.
El objetivo de esta fase fue crear un clúster de EMR con la configuración necesaria para ejecutar el procesamiento del archivo observations.tsv.

Durante este paso se realizó lo siguiente:

1. Acceder al servicio Amazon EMR desde la consola de AWS.
2. Seleccionar la opción de crear un nuevo clúster.
3. Elegir la versión de EMR v7.12.0.
4. Seleccionar paquete de aplicaciones Spark Interactive.
5. Configurar las instancias del clúster de tipo m4.large.
6. Revisar la configuración general y lanzar el clúster.

Preparación del entorno en Amazon EMR

Amazon EMR > EMR en EC2: Clústeres > EduJavierCluster

El clúster "EduJavierCluster" se ha creado correctamente.

EduJavierCluster

Se ha actualizado hace 2 minutos | Terminar | Clonar en AWS CLI | Clonar

Resumen

Información del clúster

ID del clúster
j-3U6XB8V2XVEEI

ARN del clúster
arn:aws:elasticmapreduce:us-east-1:291423576109:cluster/j-3U6XB8V2XVEEI

Configuración del clúster
Grupos de instancias

Capacidad
1 Primary (Principal) | 1 Principal | 1 Tarea

Aplicaciones

Versión de Amazon EMR
emr-7.12.0

Aplicaciones instaladas
Hadoop 3.4.1, Hive 3.1.3, JupyterEnterpriseGateway 2.6.0, Livy 0.8.0, Spark 3.5.6

Administración de clústeres

Destino del registro en Amazon S3
aws-logs-291423576109-us-east-1/elasticmapreduce

Destino del registro en Amazon CloudWatch
/aws/emr/j-3U6XB8V2XVEEI

IU de aplicación persistente
Servidor de historial de Spark
Servidor de línea de tiempo de YARN
UI de Tez

DNS público del nodo principal
ec2-98-93-204-181.compute-1.amazonaws.com
Conectarse al nodo principal mediante SSH
Conectarse al nodo principal mediante SSM

Estado y hora

Estado
Esperando

Hora de creación
21 de marzo de 2026 21:20 (UTC+00:00)

Tiempo transcurrido
9 minutos, 50 segundos

Ejecución del proceso con Amazon EMR

1. En la consola de AWS seleccionar el clúster de EMR.

2. Nos dirigimos a la pestaña de Pasos o Steps.

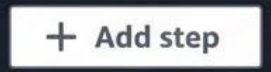

3. Hacemos clic en el botón Add step.

Añadir un nuevo paso

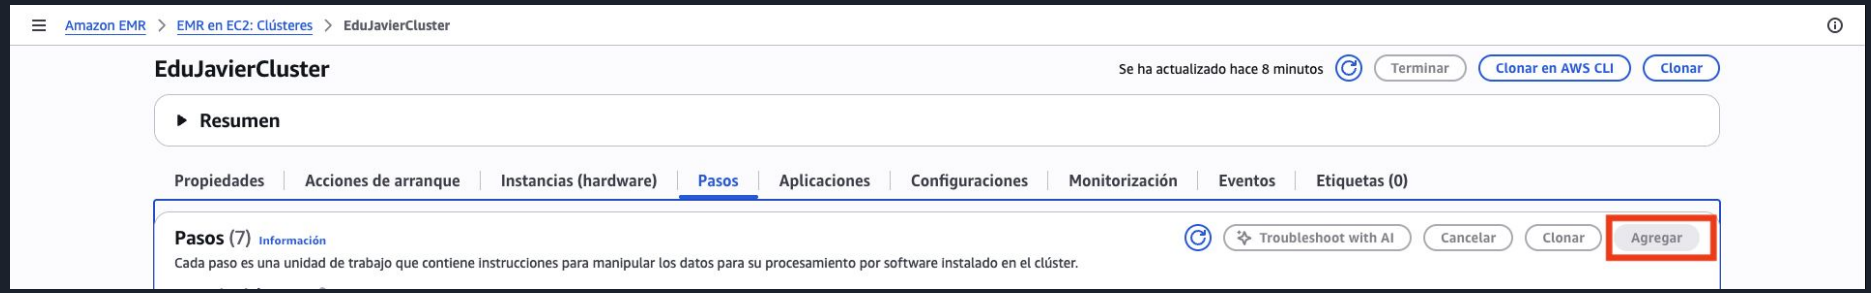

Configuración del paso

Tipo: Seleccionamos Aplicación de Spark.

Nombre: Introducimos un nombre descriptivo.

Modo implementación: Seleccionamos Modo de clúster.

Ubicación de la aplicación: Indicamos la ruta exacta del S3 donde hemos subido previamente el script de PySpark.

Argumentos (opcional): Introducimos n roducimos separadas por un espacio la ruta del dataset de entrada y la ruta donde queremos que se guarden los resultados.

Acción si ocurre un error en el paso: Seleccionamos Continue para que el clúster no se destruya si hay un error en el código.

Configuramos el paso

Amazon EMR > EMR en EC2: Clústeres > EduJavierCluster > Agregar paso

Agregar paso Información

Configuración de pasos

Tipo

- JAR personalizado
  Agrega un paso que le permite escribir un script personalizado para procesar los datos utilizando el lenguaje de programación Java.
- Programa de transmisión
  Agrega un paso que utiliza la entrada estándar para ejecutar scripts de asignación/reducción y enviar los resultados a la salida estándar.
- Programa de Hive
  Agrega un paso que envía un script de Hive para las interacciones de almacenamiento de datos.
- Aplicación de Spark
  Agrega un paso que envía el trabajo al marco de Spark en el clúster.
- Script de shell
  Solucione los problemas que se presentan con el clúster.

Nombre

Script Consulta 1

Modo implementación

- Modo de clúster
  Ejecute el controlador en un nodo de trabajo.
- Modo cliente
  Ejecute el controlador en el nodo principal como cliente externo.

Ubicación de la aplicación

La ruta al archivo JAR con su aplicación y dependencias (el modo implementación del cliente solo es compatible con la ruta local).

s3://edu-javi-bucket/script.py

Ver | Explorar S3

Ejecución

Una vez confirmada la creación haciendo clic en Add, el paso comenzará su ciclo de vida:

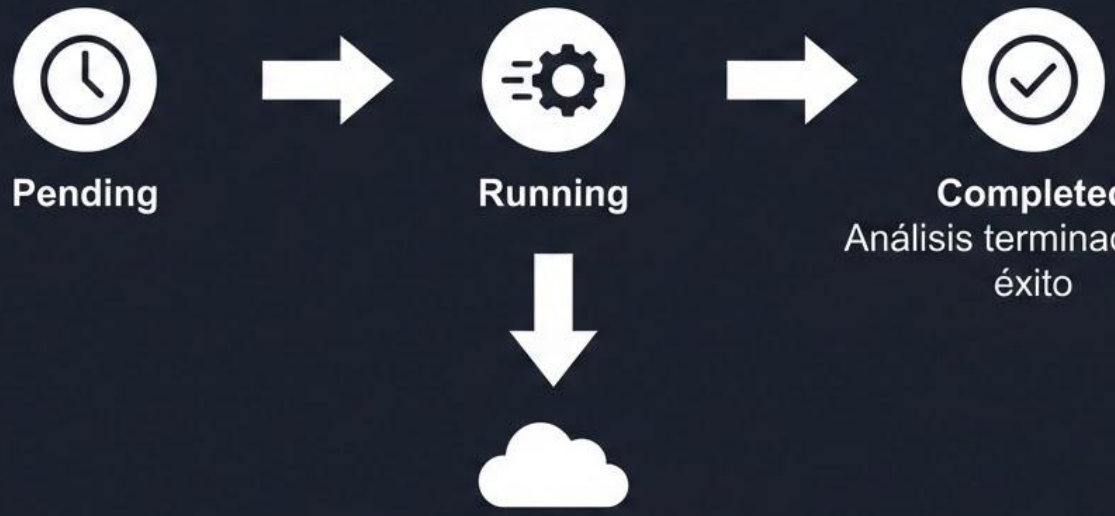

Para verificar los datos procesados, ir al bucket S3: s3://edu-javi-bucket/resultados/ para descargar y evalutar los archivos generados por PySpark.

Ejecución

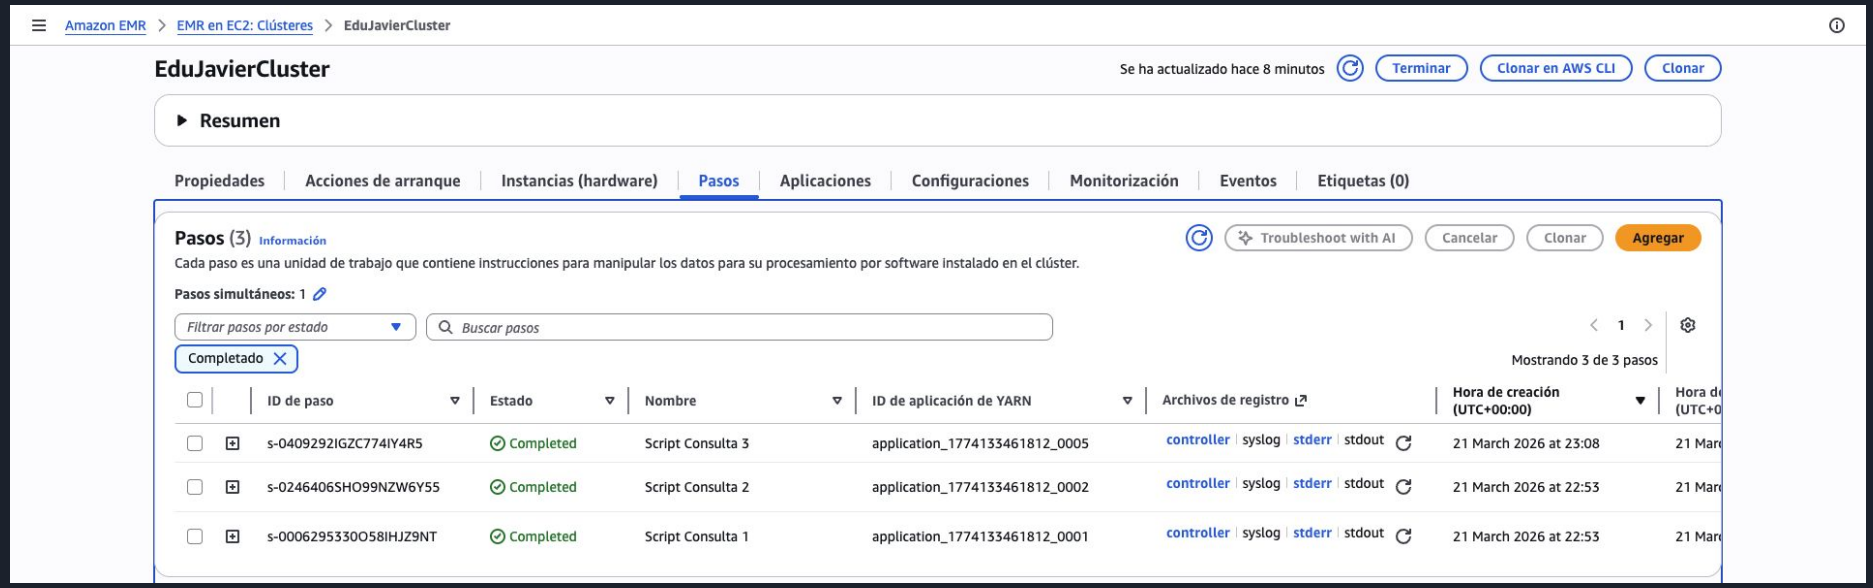
Amazon EMR > EMR en EC2: Clústeres > EduJavierCluster
EduJavierCluster
Se ha actualizado hace 8 minutos
Terminar
Clonar en AWS CLI
Clonar
Resumen
Propiedades
Acciones de arranque
Instancias (hardware)
Pasos
Aplicaciones
Configuraciones
Monitorización
Eventos
Etiquetas (0)
Pasos (3) Información
Cada paso es una unidad de trabajo que contiene instrucciones para manipular los datos para su procesamiento por software instalado en el clúster.
Troubleshoot with AI
Cancelar
Clonar
Agregar
Pasos simultáneos: 1
Filtrar pasos por estado
Buscar pasos
Completado
Mostrando 3 de 3 pasos
ID de paso
Estado
Nombre
ID de aplicación de YARN
Archivos de registro
Hora de creación (UTC+00:00)
s-0409292IGZC774IY4R5
Completed
Script Consulta 3
application_1774133461812_0005
controller | syslog | stderr | stdout
21 March 2026 at 23:08
s-0246406SHO99NZW6Y55
Completed
Script Consulta 2
application_1774133461812_0002
controller | syslog | stderr | stdout
21 March 2026 at 22:53
s-0006295330O58IHJZ9NT
Completed
Script Consulta 1
application_1774133461812_0001
controller | syslog | stderr | stdout
21 March 2026 at 22:53

Resultado en S3

Para verificar que los datos se han procesado correctamente, nos dirigimos a nuestro bucket de S3 s3://edu-javi-bucket/resultados/ donde encontraremos los archivos generados por PySpark listos para su descarga y evaluación.

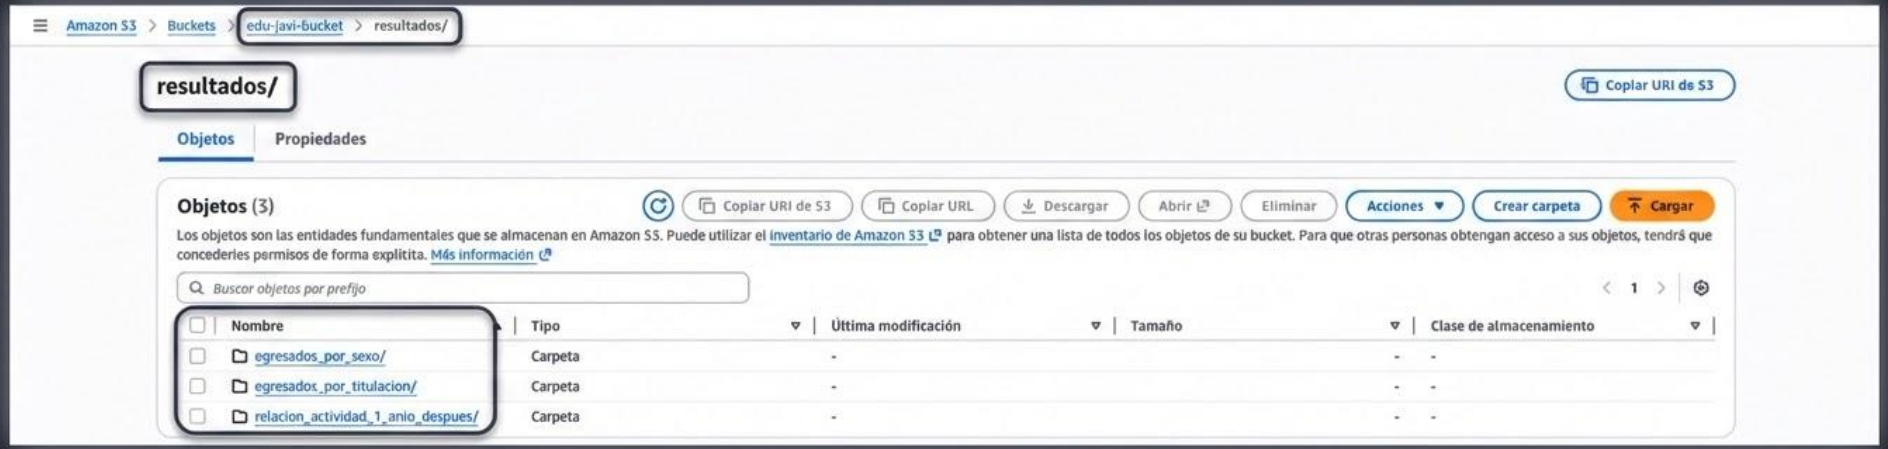

Análisis e interpretación de los datos

Distribución de egresados por titulación

El primer análisis se centró en la distribución total de egresados por titulación.

Distribución de egresados según el sexo

En el segundo análisis se estudió la distribución de los egresados según la variable `SEXO`.

Distribución de los egresados según la relación con la actividad un año después del egreso

El tercer análisis se centró en la variable `RELACION_ACTIVIDAD`, aplicando previamente el filtro `TIEMPO_EGRESO = "4 trimestres` después del egreso'.

Distribución de egresados por titulación

Los resultados muestran que algunas categorías presentan un volumen especialmente alto, como CFGS (LOE), CFGM (LOE), Administración y Gestión, Servicios Socioculturales y a la Comunidad y Sanidad. Esto indica que una parte importante de los egresados del conjunto de datos se concentra en ramas formativas relacionadas con administración, servicios sociales y sanitarios.

	TITULACION	Total_Egresados
0	CFGS (LOE)	2165616.0
1	CFGM (LOE)	1270624.0
2	Administración y Gestión	657208.0
3	Servicios Socioculturales y a la Comunidad	587224.0
4	Sanidad	394216.0
...	...	...
158	Mantenimiento de estructuras de madera y mobil...	304.0
159	Construcción	160.0
160	Gestión del agua	144.0
161	Inteligencia artificial y Big Data	112.0
162	Instalación y mantenimiento de sistemas conect...	16.0

SCRIPT CSV

Distribución de egresados según el sexo

En el segundo análisis se estudió la distribución de los egresados según la variable SEXO. Para ello, se agruparon los datos y se calculó el total de egresados en cada categoría.

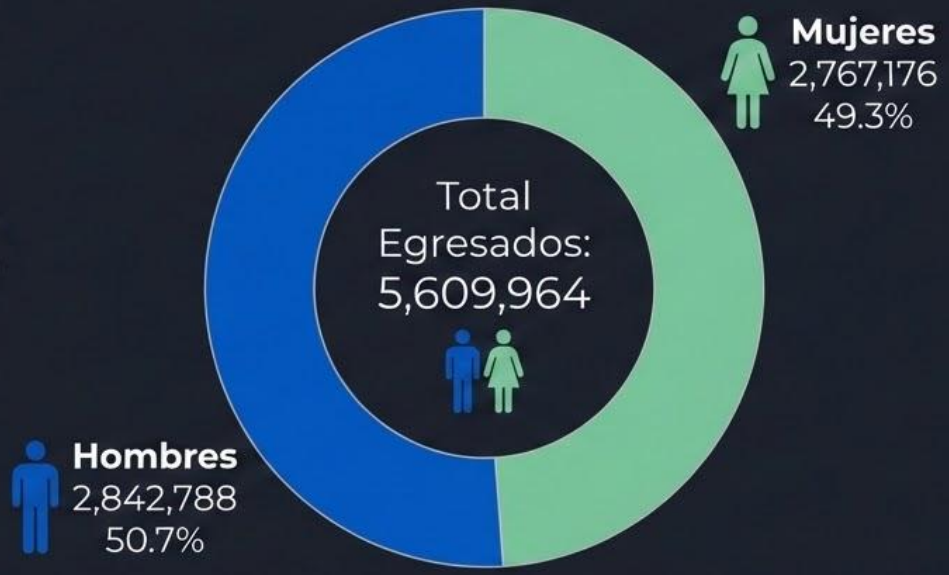

SCRIPT CSV

Distribución de los egresados según la relación con la actividad un año después del egreso

🔎 El tercer análisis se centró en la variable **RELACION_ACTIVIDAD**.
🔻 Se aplicó el filtro **TIEMPO_EGRESO** = “4 trimestres después del egreso”.
- Distibucion_a_actividad.

📅 El estudio se enfoca en la situación exacta un año después de finalizar los estudios, sin mezclar momentos temporales.

	RELACION_ACTIVIDAD	Total_Egresados
0	Personas asalariadas registradas	297900.0
1	Otro	141360.0
2	Personas desempleadas registradas	123660.0
3	Estudiantes	98268.0
4	Personas que trabajan por cuenta propia	11568.0

SCRIPT CSV

FIN