EMR
Elastic MapReduce

Eduardo Viera

Javier Rico

Índice

Introducción

¿Qué es EMR?

¿Para que se utiliza?

Arquitectura de EMR

Características principales

¿Qué problemas resuelve?

Casos de uso

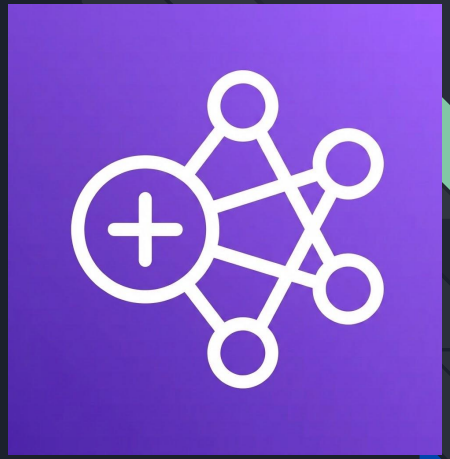

Introducción

El nombre EMR viene de Amazon Elastic MapReduce, aunque hoy AWS lo presenta como una plataforma más amplia para ejecutar frameworks de big data, no solo MapReduce.

¿Qué es EMR?

Amazon EMR es una plataforma administrada de clústeres que simplifica la ejecución de herramientas como Apache Hadoop y Apache Spark sobre AWS.
Su objetivo es evitar montar toda la infraestructura manualmente.

01

Servicio de AWS
para procesamiento de datos a gran escala.

02

Plataforma administrada
para ejecutar frameworks de big data.

03

Análisis y Transformación
Permite analizar, transformar y mover grandes volúmenes de datos.

¿Para qué se utiliza?

01

Análisis de Big Data:
Procesa datos a gran escala para descubrir patrones ocultos.

02

ETL y pipelines de datos:
Extrae, transforma y prepara datos desde múltiples fuentes a escala.

03

Procesamiento en tiempo real:
Analiza flujos de datos en streaming para casos de monitoreo y respuesta inmediata.

04

Preparación de datos para Machine Learning:
Ejecuta procesamiento distribuido para entrenar y alimentar modelos con frameworks como Apache Spark.

Arquitectura de EMR

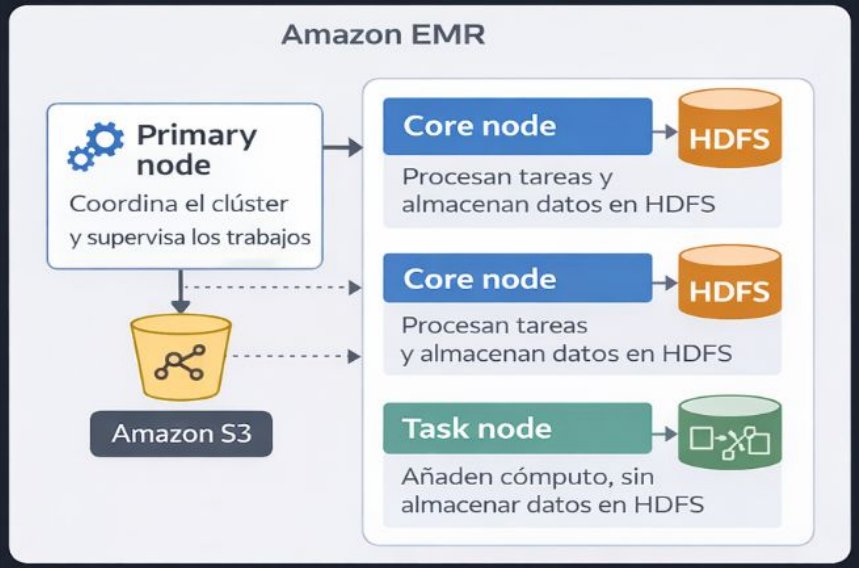

Primary node: Coordina el clúster, administra recursos y supervisa la ejecución de los trabajos.

Core nodes: Ejecutan tareas de procesamiento y almacenan datos en HDFS del clúster..

Task nodes: Añaden capacidad de cómputo para procesamiento paralelo, sin almacenar datos en HDFS.

Nota: En muchos entornos, Amazon S3 se usa como almacenamiento persistente y HDFS para datos temporales.

Funcionamiento de EMR

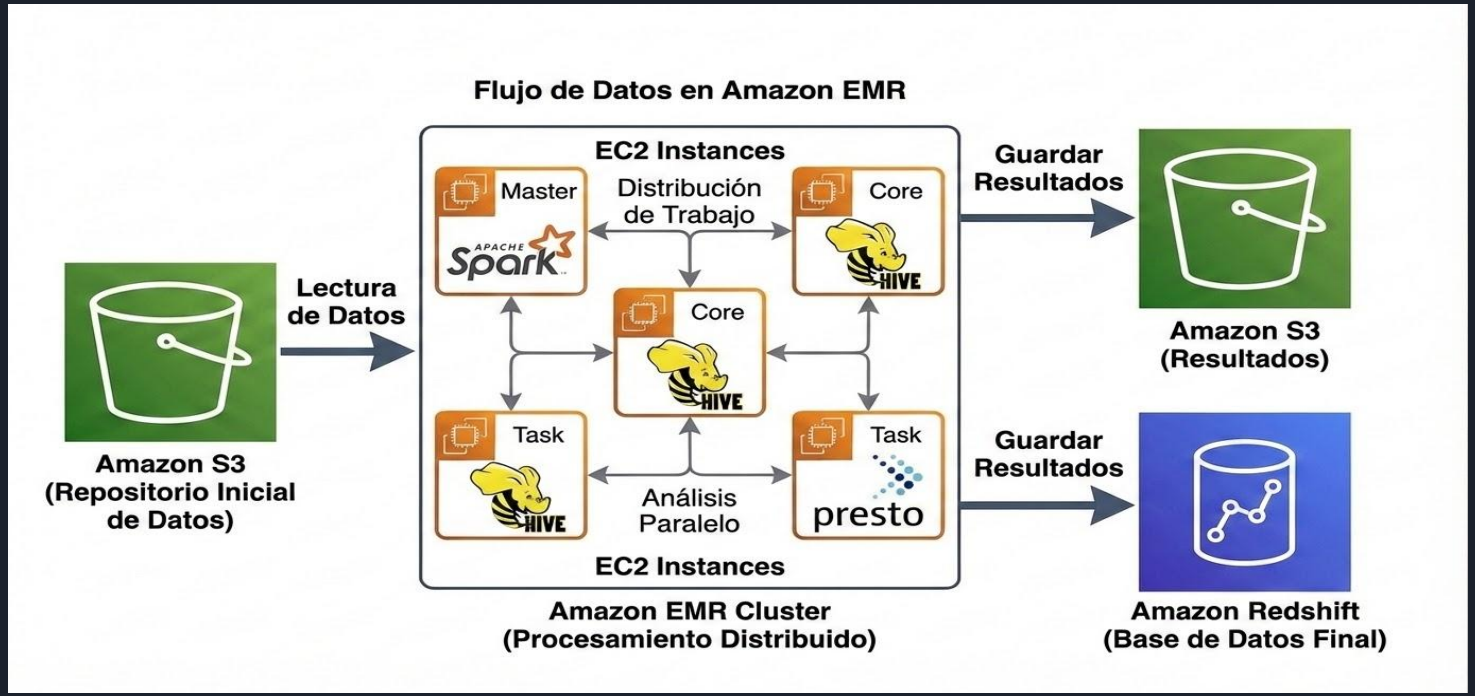

Características principales

Servicio Gestionado

AWS hace el trabajo pesado se encarga de aprovisionar, configurar y ajustar los servidores por ti.

Escalabilidad Elástica

El clúster puede crecer o encogerse automáticamente sobre la marcha dependiendo de la cantidad de datos que necesites procesar.

Rentabilidad

Pagas por segundo de uso y permite utilizar Instancias Spot para reducir costes drásticamente.

Almacenamiento Flexible

Se integra de forma nativa y directa con Amazon S3.

Ecosistema Open Source

Es compatible con las herramientas líderes de Big Data de la industria, como Apache Spark, Hadoop, Hive o Presto.

¿Qué problemas resuelve?

Procesar datasets demasiado grandes para un solo equipo.

Escalar recursos según la carga.

Reducir la complejidad de instalar y mantener Hadoop/Spark.

Mejorar tiempos de procesamiento.

Casos de Usos

Procesamiento masivo de logs

Análisis de grandes volúmenes de datos

ETL de datos

Transformación de archivos CSV/JSON/Parquet

Análisis de datos para business intelligence

Preparación de datos para machine learning

Ejemplo Real:

Una empresa guarda millones de registros en S3 y usa EMR con Spark para limpiarlos, agruparlos y generar resultados para analizarlos después

FIN